TP Optimisation

Hennechart Arthur et Khyar Zouheir

9 avril 2026

Table des matières

1 Introduction **2**

2 Optimisation Linéaire **2**
2.1 Méthode exhaustive 2
2.2 Simplex 1-phase 3
2.3 Simplex 2-phase 3

3 Optimisation unidimensionnelle **4**
3.1 Méthode du Golden Section 4
3.2 Méthodes Newton et Secant 5

4 Optimisation multidimensionnelle **6**
4.1 Fonction de Rosenbrock 6
4.2 Application de Steepest Descent 6
4.3 Cas quadratiques – Descente de gradient 7

5 Commentaires généraux **8**

1 Introduction

Ce rapport présente les résultats du TP sur l'optimisation numérique. Les méthodes étudiées sont :

— **Optimisation linéaire :** méthode exhaustive, simplex 1-phase et 2-phase.

— **Optimisation unidimensionnelle :** méthode du Golden Section, Newton et Secant.

— **Optimisation multidimensionnelle :** descente de gradient sur des fonctions quadratiques et la fonction de Rosenbrock.

Toutes les figures ont été générées via MATLAB et exportées pour illustrer les trajectoires et minima obtenus.

2 Optimisation Linéaire

2.1 Méthode exhaustive

La méthode exhaustive consiste à tester toutes les combinaisons de colonnes de A pour trouver les bases admissibles.

L'algorithme utilisé est de nature itérative et explore exhaustivement l'ensemble des combinaisons $\binom{n}{m}$ afin de sélectionner des sous-ensembles de colonnes de la matrice A. Si le rang de la matrice A est strictement inférieur à m ou si $m \geq n$, l'algorithme s'interrompt de manière anticipée.

Test 1 :

$$A = \begin{bmatrix} 1 & 1 & -1 & 4 \\ 1 & -2 & -1 & 1 \end{bmatrix}, \quad b = \begin{bmatrix} 8 \\ 2 \end{bmatrix}, \quad c = \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix}$$

$$f_{\text{opt}} = 2, \quad x_{\text{opt}} = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 2 \end{bmatrix}, \quad B = [2, 4]$$

Test 2 :

$$A = \begin{bmatrix} 4 & 2 & -1 & 0 \\ 1 & 4 & 0 & -1 \end{bmatrix}, \quad b = \begin{bmatrix} 12 \\ 6 \end{bmatrix}, \quad c = \begin{bmatrix} 2 \\ 3 \\ 0 \\ 0 \end{bmatrix}$$

$$f_{\text{opt}} = 7.7143, \quad x_{\text{opt}} = \begin{bmatrix} 2.5714 \\ 0.8571 \\ 0 \\ 0 \end{bmatrix}, \quad B = [1, 2]$$

2.2 Simplex 1-phase

La méthode du simplexe à une phase repose sur le choix d'une base initiale admissible afin de construire un tableau canonique. À chaque itération, on examine la dernière ligne du tableau pour déterminer si un pivot doit être effectué. Le procédé est répété jusqu'à l'obtention d'une solution optimale.

Considérons l'exemple suivant :

$$A = \begin{bmatrix} 2 & 0 & -2 & 4 & 0 \\ 2 & -4 & 0 & -2 & 0 \\ 2 & 0 & 1 & 1 & 1 \end{bmatrix}, \quad b = \begin{bmatrix} 4 \\ 6 \\ 10 \end{bmatrix}, \quad c = \begin{bmatrix} -4 \\ 4 \\ 2 \\ -2 \\ 0 \end{bmatrix}.$$

La base initiale choisie est

$$B = [a_1, a_3, a_5].$$

Le résultat obtenu est

$$f_{\text{opt}} = -10, \quad x_{\text{opt}} = \begin{bmatrix} 3 \\ 0 \\ 1 \\ 0 \\ 3 \end{bmatrix}, \quad B = [1, 3, 5].$$

2.3 Simplex 2-phase

La méthode du simplexe à deux phases est utilisée lorsqu'aucune base initiale admissible n'est directement disponible. La première phase permet de construire une solution de base admissible, tandis que la seconde phase applique l'algorithme du simplexe classique pour atteindre l'optimum. Notre algorithme applique le Simplex 1-Phase si une base initiale est retrouvée, sinon il fait deux appels à notre fonction Simplex 1-Phase, la première pour déterminer une base et la seconde pour résoudre le tableau.

Pour l'exemple suivant,

$$A = \begin{bmatrix} 4 & 2 & -1 & 0 \\ 1 & 4 & 0 & -1 \end{bmatrix}, \quad b = \begin{bmatrix} 12 \\ 6 \end{bmatrix}, \quad c = \begin{bmatrix} 2 \\ 3 \\ 0 \\ 0 \end{bmatrix},$$

on obtient le résultat suivant :

$$f_{\text{opt}} = 7.7143, \quad x_{\text{opt}} = \begin{bmatrix} 2.5714 \\ 0.8571 \\ 0 \\ 0 \end{bmatrix}, \quad B = [a_1, a_2].$$

Commentaire :

Les méthodes du simplexe conduisent aux mêmes solutions que la méthode exhaustive lorsque la base initiale est admissible. Avec :

$$A = \begin{bmatrix} 2 & 0 & -2 & 4 & 0 \\ 2 & -4 & 0 & -2 & 0 \\ 2 & 0 & 1 & 1 & 1 \end{bmatrix}, \quad b = \begin{bmatrix} 4 \\ 6 \\ 10 \end{bmatrix}, \quad c = \begin{bmatrix} -4 \\ 4 \\ 2 \\ -2 \\ 0 \end{bmatrix}.$$

On obtient ce meme resultat sur les trois algorithmes

$$f_{\text{opt}} = -10, \quad x_{\text{opt}} = \begin{bmatrix} 3 \\ 0 \\ 1 \\ 0 \\ 3 \end{bmatrix}, \quad B = [a_1, a_3, a_5].$$

3 Optimisation unidimensionnelle

3.1 Méthode du Golden Section

Fonction test : $f(x) = x^4 + 4x^3 + 9x^2 + 6x + 6$

Résultat :

$$x_{\text{opt}} = -0.4482$$

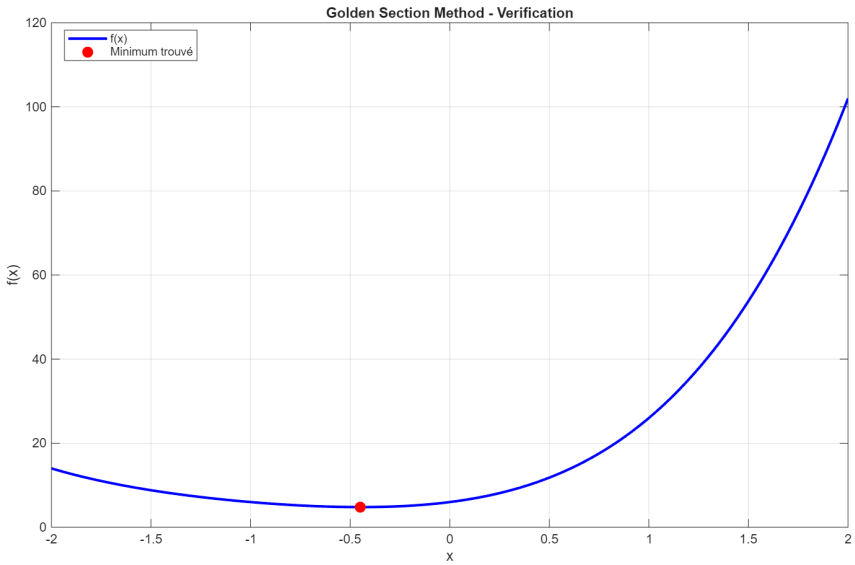

FIGURE 1 – Méthode du Golden Section pour $f(x)$. Le point rouge indique le minimum trouvé.

3.2 Méthodes Newton et Secant

Fonction test : $f(x) = 2x^4 - 5x^3 + 100x^2 + 30x - 75$

$$x_{\text{Newton}} = -0.1482, \quad x_{\text{Secant}} = -0.1482$$

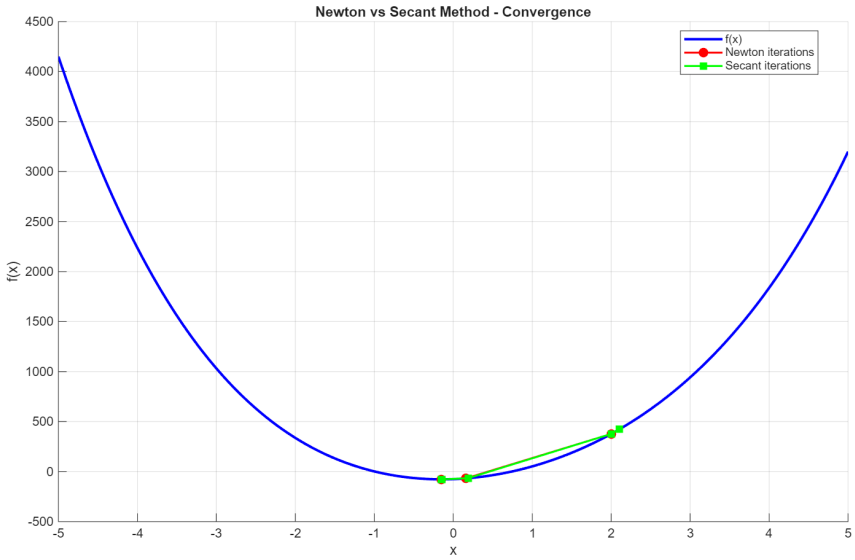

FIGURE 2 – Comparaison des méthodes Newton et Secant. Les points rouges représentent les itérations de Newton et les verts celles de Secant.

4 Optimisation multidimensionnelle

4.1 Fonction de Rosenbrock

Point initial : $x_0 = [-1, 2]$

$$x_{\min} = [0.8595, 0.7403], \quad f(x_{\min}) = 0.019986$$

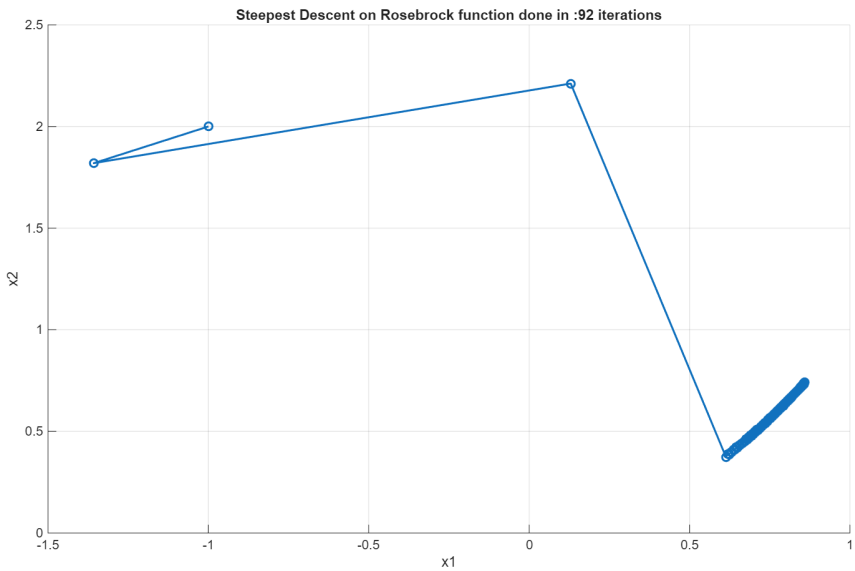

FIGURE 3 – Trajectoire de la méthode de Steepest Descent sur la fonction de Rosenbrock.

Un agrandissement de la trajectoire montre que la convergence ralentit et adopte une forme en zigzag, ce qui illustre la difficulté de minimisation de la fonction de Rosenbrock. Le minimum global exact est atteint en $[1, 1]$, unique extremum satisfaisant les conditions nécessaires et suffisantes d'optimalité dans ce cas.

4.2 Application de Steepest Descent

Considérons le problème d'optimisation suivant :

$$\min_{x \in \mathbb{R}^2} f(x) = (2x_1^2 - x_2)^2 + 3x_1^2 - x_2.$$

La méthode du *Steepest Descent* consiste à calculer le gradient de la fonction, puis à déterminer un pas optimal par recherche linéaire. À partir du point initial

$$x_0 = \begin{bmatrix} \frac{1}{2} \\ \frac{5}{4} \end{bmatrix},$$

on obtient le gradient et la matrice hessienne suivants :

$$\nabla f(x) = \begin{bmatrix} 16x_1^3 - 8x_1x_2 + 6x_1 \\ -4x_1^2 + 2x_2 - 1 \end{bmatrix}, \qquad H(x) = \begin{bmatrix} 48x_1^2 - 8x_2 + 6 & -8x_1 \\ -8x_1 & 2 \end{bmatrix}.$$

Le pas optimal est alors calculé par

$$\alpha = \frac{\nabla f(x_0)^T \nabla f(x_0)}{\nabla f(x_0)^T H(x_0) \nabla f(x_0)} = 0.5.$$

Le point suivant obtenu après une itération est donc

$$x_1 = \begin{bmatrix} 0.5 \\ 1.0 \end{bmatrix}.$$

En ce point, la matrice hessienne est définie positive, ce qui montre que la fonction est localement convexe au voisinage de x_1.

4.3 Cas quadratiques – Descente de gradient

- Cas 1 : $Q = 6I$, convergence en 1 itération
- Cas 2 : $Q = \begin{bmatrix} 10 & 0 \\ 0 & 1 \end{bmatrix}$, convergence en 15 itérations
- Cas 3 : $Q = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}$, convergence en 50 itérations

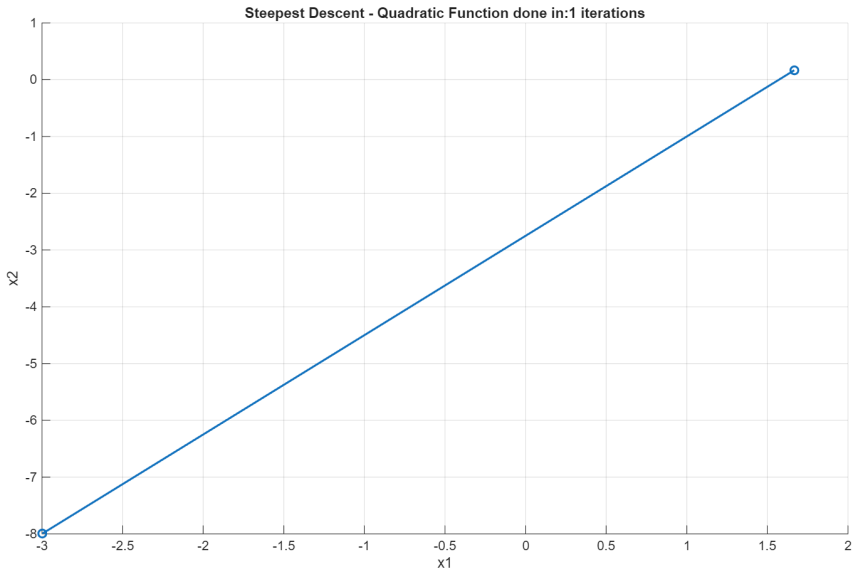

FIGURE 4 – Trajectoires des méthodes de descente de gradient pour le cas 1.

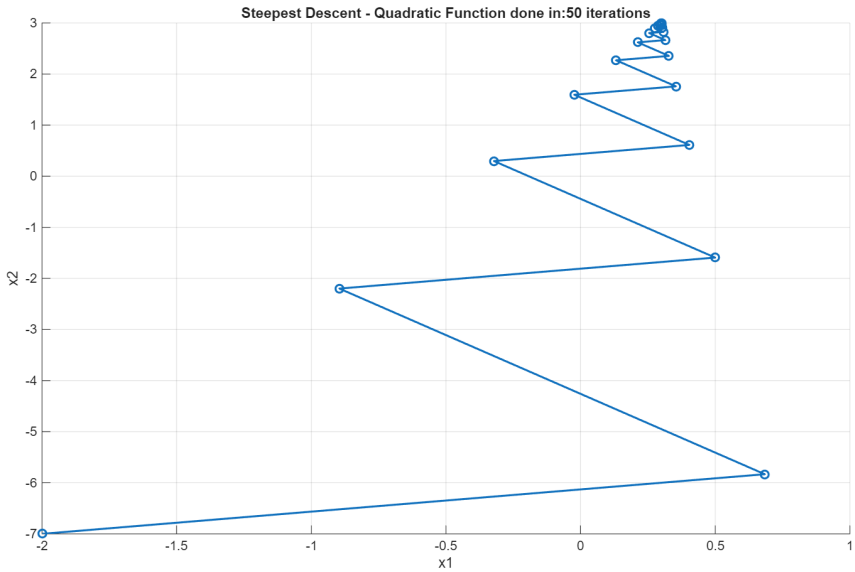

FIGURE 5 – Trajectoires des méthodes de descente de gradient pour le cas 2.

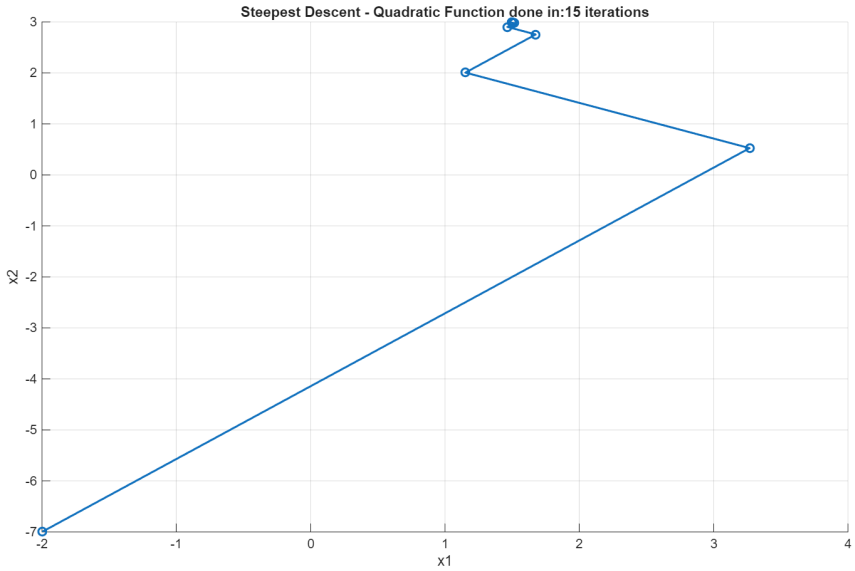

FIGURE 6 – Trajectoires des méthodes de descente de gradient pour le cas 3.

Le cas 1 converge le plus rapidement, suivi du cas 3, enfin le cas 2.

5 Commentaires généraux

- Nous utilisons des algorithmes itératifs classiques pour chaque méthode de recherche
- Les méthodes d'optimisation linéaire donnent des solutions exactes pour les petites matrices.
- La méthode Golden Section est robuste mais moins rapide que Newton ou Secant.
- La descente de gradient multidimensionnelle dépend fortement du point initial et du conditionnement de la matrice Hessienne.
- Les figures montrent clairement la convergence et les trajets suivis par chaque méthode.
- Pour Rosenbrock, le minimum exact est $[1, 1]$, tandis que Steepest Descent s'arrête à une approximation $[0.8595, 0.7403]$ due à la tolérance et au point initial.